



Universidad Autónoma De Baja California

Ingeniería en computación

Ingeniería de negocios

**Meta 4.1.Construir un Data Warehouse y Desarrollar
los Elementos Visuales que forman parte de un
sistema de soporte de decisiones**

SUKEY SAYONARA NAKASIMA LOPEZ

Garcia Chavez Erik - 01275863

Armando Tepale Chicolatl - 1280222


Andrea Sofia Chavez Munguia - 1279990

paso 1. objetivos:

- **objetivo 1: Cuantificar la magnitud y el impacto económico del fraude**
 - **Justificación:** Antes de implementar cualquier solución tecnológica, la gerencia necesita conocer la línea base del problema. Este objetivo permite dimensionar la pérdida real (en moneda local – AED) y la frecuencia con la que ocurren eventos fraudulentos. Sin estas métricas, no es posible evaluar el retorno de inversión de las medidas antifraude
 - **métricas clave asociadas:**
 - **Tasa de fraude general (%)** – porcentaje de transacciones fraudulentas sobre el total.
 - **Pérdida económica total (AED)** – sumatoria de los montos de todas las transacciones marcadas como fraudulentas.
 - **Aportación al SSD:**
 - Se construirán visualizadores tipo KPI y tarjeta (card) para mostrar estos indicadores de alto nivel. Además, se utilizarán segmentadores (slicers) para analizar cómo varían estas métricas por período de tiempo, método de pago o nivel de riesgo de IP.
- **Objetivo 2: Detectar vulnerabilidades operativas en el proceso de compra**
 - **Justificación:** Los delincuentes suelen explotar los canales con barreras de seguridad más débiles. Este objetivo audita el entorno tecnológico (métodos de pago, direcciones IP, dominios de correo, discrepancias geográficas) para identificar los puntos ciegos del sistema y priorizar acciones preventivas.
 - **métricas asociadas:**
 - **Incidencia de fraude por método de pago (%)** – concentración de ataques exitosos por canal financiero.
 - **Brecha de riesgo de IP** – comparación del puntaje promedio de IP entre transacciones legítimas y fraudulentas.
 -
 - **Aportación al SSD:** Se emplearán tablas, gráficos de barras y segmentadores para visualizar la distribución del fraude por método de pago, y se creará una columna calculada que clasifique cada transacción como “Alto Riesgo IP” o “Bajo Riesgo IP”. Esto permitirá a los tomadores de decisión aplicar filtros rápidos y enfocar los recursos en los canales más vulnerables.

paso 2. aplicar ETL para generar el modelo estrella

- tablas propuestas:



- columnas originales del dataset:
 - transaction_id, user_id, timestamp_utc, amount_aed, currency, payment_method, device_type, browser, merchant_category, items_count, avg_item_price, shipping_city, billing_city, shipping_billing_match, ip_address, ip_risk_score, card_present, bin_country, card_age_days, card_country_match, email_domain, user_prev_chargebacks, user_is_high_risk, user_account_age_days, transactions_last_24h, transactions_last_1h, local_hour, odd_hour, is_fraud, fraud_flag_ip, fraud_flag_mismatch, fraud_flag_velocity, fraud_flag_new_account, fraud_flag_prev_cb, fraud_flag_odd_hour, data_source
- transformaciones

acción	columnas afectadas	razón
creacion de tabla de hechos Fact_Transacciones	Conservar: transaction_id, user_id, timestamp_utc, amount_aed, payment_method, ip_risk_score, items_count, avg_item_price, is_fraud	La tabla de hechos debe contener eventos medibles (transacciones) y claves foráneas que conectan con las dimensiones.
Crear dimensión Dim_Usuario	Conservar: user_id, email_domain, user_prev_chargebacks, user_is_high_risk, user_account_age_days	Agrupar todos los atributos del cliente/usuario
Crear dimensión Dim_MetodoPago	Conservar: payment_method	Agrupar los métodos de pago únicos
Creación de Dim_Tiempo con DAX	Se genera a partir de timestamp_utc	El tiempo es una dimensión fundamental para análisis temporales.

- justificación de las transformaciones de las tablas:

■ **Selección de columnas para la tabla de hechos:**

Se conservaron en Fact_Transacciones las columnas transaction_id, user_id, timestamp_utc, amount_aed, payment_method, ip_risk_score, items_count, avg_item_price e is_fraud. Estas columnas representan los eventos medibles (cada transacción) y las claves foráneas que conectan con las dimensiones. El resto de las columnas fueron excluidas porque son atributos descriptivos que no aportan valor como métricas o porque carecen de una clave única para convertirse en dimensiones.

■ **Creación de dimensiones separadas:**

Se crearon tres dimensiones independientes: Dim_Usuario (datos del cliente), Dim_MetodoPago (métodos de pago) y Dim_Tiempo (fechas). Estas dimensiones permiten analizar el fraude desde perspectivas clave: por antigüedad de cuenta, por dominio de correo, por método de pago y por evolución temporal. No se crearon dimensiones para device_type, browser, merchant_category, shipping_city, fraud_flag_*, etc., porque estas columnas no cuentan con una clave única que permita establecer una relación adecuada en el modelo estrella.

■ **Eliminación de duplicados en dimensiones**

En Dim_Usuario se eliminan duplicados usando user_id como clave primaria. En Dim_MetodoPago se eliminan duplicados usando payment_method. Esto es necesario porque una dimensión debe funcionar como un catálogo de entidades únicas. Si hubiera duplicado, las relaciones serían incorrectas y provocaría errores en los filtros y agregaciones.


■ **No eliminación de duplicados en la tabla de hechos**

En Fact_Transacciones no se eliminan duplicados porque cada fila representa una transacción única identificada por transaction_id. Aunque puedan existir filas con el mismo user_id o payment_method, cada una es un evento diferente. Eliminar duplicados en la tabla de hechos implicaría perder información real de transacciones, lo cual es inaceptable en un sistema de soporte de decisiones.

■ **Creación de la dimensión tiempo con DAX**

La tabla Dim_Tiempo se generó mediante la función CALENDAR en DAX, tomando las fechas mínima y máxima de Fact_Transacciones. Se añadieron columnas derivadas (año, mes, trimestre, día) para habilitar análisis temporales. El tiempo es una dimensión transversal indispensable en cualquier Data Warehouse.

- modelo estrella relacion entre tablas:



paso 3. generar cálculos y medidas DAX:

- **columna calculada:riesgo_IP_ALTO**

- **necesidad y justificación:**

Esta columna permite clasificar cada transacción según el nivel de riesgo de la dirección IP, se considerará de alto riesgo si ip_risk_score es mayor que 70. Ayuda a los tomadores de decisión a filtrar rápidamente (mediante un segmentador o slicer) las transacciones de alto riesgo y analizar su comportamiento. Es una forma sencilla de auditar la vulnerabilidad por IP

- **muestra**

Riesgo_IP_Alto = IF(Fact_Transacciones[ip_risk_score] > 70, "Alto Riesgo", "Bajo Riesgo")											Data
ion_id	user_id	timestamp_utc	amount_aed	payment_method	items_count	avg_item_price	ip_risk_score	is_fraud	fecha_sola	Fecha_Clave	Riesgo_IP_Alto
100074210	1015925	1/5/2024 6:49:51 PM	71.95	card	2	35.98	0	0	1/5/2024 12:00:00 AM	20240105	Bajo Riesgo
100032330	1010283	1/6/2024 12:17:12 AM	33.94	card	2	16.97	0	0	1/6/2024 12:00:00 AM	20240106	Bajo Riesgo
100040622	1002240	1/9/2024 12:43:31 PM	109.75	card	2	54.88	0	0	1/9/2024 12:00:00 AM	20240109	Bajo Riesgo
100013515	1002316	1/13/2024 11:37:57 PM	56.5	card	2	28.25	0	0	1/13/2024 12:00:00 AM	20240113	Bajo Riesgo
100092794	1028657	1/15/2024 10:59:37 AM	112.73	card	2	56.36	0	0	1/15/2024 12:00:00 AM	20240115	Bajo Riesgo
100034393	1026626	1/16/2024 11:49:29 PM	40.53	card	2	20.26	0	0	1/16/2024 12:00:00 AM	20240116	Bajo Riesgo
100060945	1002476	1/17/2024 6:26:01 AM	41.93	card	2	20.96	0	0	1/17/2024 12:00:00 AM	20240117	Bajo Riesgo
100014540	1025959	1/17/2024 11:32:35 PM	41.9	card	2	20.95	0	0	1/17/2024 12:00:00 AM	20240117	Bajo Riesgo
100021958	1014158	1/25/2024 5:25:12 AM	25.52	card	2	12.76	0	0	1/25/2024 12:00:00 AM	20240125	Bajo Riesgo
100082794	1009553	1/29/2024 3:44:35 AM	33.62	card	2	16.81	0	0	1/29/2024 12:00:00 AM	20240129	Bajo Riesgo
100055557	1024821	2/2/2024 10:00:47 PM	14.77	card	2	7.38	0	0	2/2/2024 12:00:00 AM	20240202	Bajo Riesgo
100009924	1023627	2/3/2024 11:38:32 PM	93.11	card	2	46.56	0	0	2/3/2024 12:00:00 AM	20240203	Bajo Riesgo
100090079	1025241	2/4/2024 4:14:20 AM	237.9	card	2	118.95	0	0	2/4/2024 12:00:00 AM	20240204	Bajo Riesgo
100024595	1020913	2/16/2024 9:30:47 AM	80.56	card	2	40.28	0	0	2/16/2024 12:00:00 AM	20240216	Bajo Riesgo
100044112	1003444	2/16/2024 8:30:13 PM	26.13	card	2	13.06	0	0	2/16/2024 12:00:00 AM	20240216	Bajo Riesgo
100081709	1018747	2/23/2024 8:54:46 PM	23.12	card	2	11.56	0	0	2/23/2024 12:00:00 AM	20240223	Bajo Riesgo
100087656	1016785	2/25/2024 1:11:45 PM	45.48	card	2	22.74	0	0	2/25/2024 12:00:00 AM	20240225	Bajo Riesgo
100088143	1013562	2/26/2024 1:00:38 AM	25.73	card	2	12.86	0	0	2/26/2024 12:00:00 AM	20240226	Bajo Riesgo
100066384	1015403	2/28/2024 3:02:08 PM	207.39	card	2	103.7	0	0	2/28/2024 12:00:00 AM	20240228	Bajo Riesgo
100031522	1026993	3/6/2024 7:30:36 PM	6.01	card	2	3	0	0	3/6/2024 12:00:00 AM	20240306	Bajo Riesgo
100092199	1025203	3/13/2024 7:39:17 AM	125.05	card	2	62.52	0	0	3/13/2024 12:00:00 AM	20240313	Bajo Riesgo
100074538	1021812	3/15/2024 4:14:12 AM	125.56	card	2	62.78	0	0	3/15/2024 12:00:00 AM	20240315	Bajo Riesgo
100033455	1018510	3/18/2024 1:14:02 AM	128.98	card	2	64.49	0	0	3/18/2024 12:00:00 AM	20240318	Bajo Riesgo
100075223	1000141	3/21/2024 2:14:39 PM	221.65	card	2	110.82	0	0	3/21/2024 12:00:00 AM	20240321	Bajo Riesgo
100019946	1015873	3/22/2024 9:34:27 PM	205.67	card	2	102.84	0	0	3/22/2024 12:00:00 AM	20240322	Bajo Riesgo
100019043	1008578	4/1/2024 2:26:10 PM	25.29	card	2	12.64	0	0	4/1/2024 12:00:00 AM	20240401	Bajo Riesgo

- **medida 1: Tasa_fraude_%**


- **necesidad y justificación:**

Esta medida es dinámica: responde a cualquier filtro (fechas, usuario, método de pago, etc.). Se usará en un KP para mostrar el porcentaje de fraude en tiempo real. Permite a la gerencia evaluar si las medidas antifraude están funcionando y comparar con estándares de la industria.

- **muestra visual:**



- **measure listado:**




- **medida 2: Perdida_Fraude_AED**


- **necesidad y justificación**

Suma los montos de todas las transacciones fraudulentas. Permite dimensionar el impacto económico real del fraude, también de forma dinámica. Se emplea en una tarjeta y en tablas, permite analizar dónde se concentran las mayores pérdidas.

- **muestra visual:**




- **measure listado:**



- **creación de la tabla: *medidas fraude***

- ***Necesidad y justificación:*** Esta tabla contiene una única fila y una columna ficticia, que no se utiliza en los informes. Su único propósito es actuar como contenedor organizativo para todas las medidas del modelo. Al agrupar las medidas en una tabla separada se evita mezclarlas con las columnas de las tablas de hechos y dimensiones, lo que facilita la navegación en el panel de campos y mejora la mantenibilidad del modelo.



- **cómo se integran en el sistema de soporte de decisiones (SSD)**

Se creó una tabla de medidas independiente llamada Medidas_Fraude. Esta tabla no contiene datos reales; su único propósito es actuar como un contenedor organizativo para todas las medidas del modelo. Al centralizar los cálculos en una sola tabla, se facilita la navegación en el panel de campos, se evita mezclar medidas con columnas de datos y se mejora la mantenibilidad del sistema de soporte de decisiones (SSD). Cualquier miembro del equipo puede localizar, modificar o depurar una medida sin tener que buscar entre decenas de columnas de las tablas de hechos o dimensiones.

Medidas para cuantificar el fraude:

- **Tasa Fraude %:**
 - **Apoyo al SSD:** Esta es la métrica principal del KPI. Se utiliza en el visual KPI para mostrar el porcentaje global de fraude. Su comportamiento dinámico permite evaluar el impacto de filtros (por método de pago, fecha o nivel de riesgo IP). Si la tasa supera el 1%, el KPI se torna rojo, alertando a la gerencia.
- **Pérdida Total AED:**
 - **Apoyo al SSD:** Mide el impacto económico real del fraude. Se coloca en una tarjeta, permitiendo al tomador de decisiones conocer al instante la fuga de capital. Junto con los slicers de fecha y método de pago, se puede analizar la pérdida en segmentos específicos (por ejemplo, solo en tarjetas de crédito durante diciembre).
- **Pérdida Promedio AED:**
 - **Apoyo al SSD:** Complementa a la medida anterior mostrando el daño medio por evento fraudulento. Ayuda a dimensionar la

severidad de cada ataque. Se usa en una tarjeta secundaria o en tablas de detalle.

- **Ingresos Perdidos:**
 - **Apoyo al SSD:** Incorpora un 5% adicional de costos asociados (gestión de chargebacks, personal, comisiones). Ofrece una visión más conservadora del impacto financiero, útil para reportes gerenciales y justificación de inversiones en seguridad.

Medidas para detectar vulnerabilidades operativas:

- **Promedio IP Risk Fraude:**
 - **Apoyo al SSD:** Cuantifica el nivel de riesgo de las IPs usadas en transacciones fraudulentas. Se muestra en una tarjeta o tabla de comparación, permitiendo al analista conocer si los estafadores utilizan IPs peligrosas.
- **Promedio IP Risk Legítimo:**
 - **Apoyo al SSD:** Base de comparación (riesgo normal). Al contrastar ambos promedios, se puede validar la hipótesis de que el fraude se asocia a IPs de mayor riesgo.
- **Brecha Riesgo IP:**
 - **Apoyo al SSD:** Diferencia entre ambos promedios. Una brecha positiva y grande (mayor a 10 puntos) confirma que los estafadores usan IPs de alto riesgo. Sirve como una alerta técnica que se puede visualizar en una tarjeta con formato condicional (rojo si > 10). Esta alerta orienta la decisión de automatizar bloqueos por IP.
- **Fraudes Alto Riesgo IP:**
 - **Apoyo al SSD:** Número de fraudes que ocurren con IPs clasificadas como de alto riesgo. Se utiliza en tarjetas y tablas para dimensionar el problema.
- **% Fraudes Alto Riesgo:**
 - **Apoyo al SSD:** Porcentaje de fraude que se concentra en IPs de alto riesgo. Un valor alto (por ejemplo, $> 80\%$) indica que la regla de detección por IP sería muy efectiva. Se muestra en un gráfico de barras o tarjeta.
- **Fraude x MetodoPago:**
 - **Apoyo al SSD:** Estas medidas se utilizan en gráficos de barras con payment_method en el eje X. Permiten identificar qué canal financiero acumula más fraudes y qué canal tiene más volumen. Al combinar ambas, se puede calcular la tasa de fraude por método de pago, priorizando acciones correctivas en los más vulnerables

- **Columna calculada:**

- **¿Qué hace?:**

Clasificación Riesgo IP (en Fact_Transacciones) etiqueta cada transacción como "Alto Riesgo" si `ip_risk_score > 70`, o "Bajo Riesgo" en caso contrario. Esta columna es utilizada por las medidas de fraude por nivel de riesgo IP.

- **apoyo al SSD:**

- Promedio IP Risk Fraude y Promedio IP Risk Legítimo: permiten comparar el riesgo de IP entre transacciones fraudulentas y legítimas.
 - Brecha Riesgo IP: diferencia entre ambos promedios. Una brecha positiva y grande indica que los estafadores usan IPs de mayor riesgo.
 - Fraudes Alto Riesgo IP y % Fraudes Alto Riesgo: cuantifican la concentración del fraude en IPs clasificadas como de alto riesgo.
 - Fraude x MetodoPago y Volumen x MetodoPago: se utilizan en gráficos de barras para analizar la incidencia del fraude por canal financiero.

Paso 4. Desarrollar el sistema de soporte de decisiones.

Implementación de Segmentadores Dinámicos (Slicers)

Para dotar al reporte de interactividad y capacidad de filtrado profundo, se configuraron tres segmentadores principales. Estos elementos actúan como variables de control que recalculan las métricas de todo el lienzo en tiempo real:

Variable (Columna)	Justificación Analítica en el Proyecto
is_fraud (Estado)	Se configuró como un menú desplegable binario (0 = Legítimo, 1 = Fraude). Es el eje central del proyecto, ya que permite aislar el "ruido" de las transacciones exitosas para estudiar exclusivamente la anatomía de los ataques.
merchant_category	Permite segmentar el análisis por tipo de negocio (ej. Electrónicos, Moda). Útil para demostrar qué industrias presentan mayor vulnerabilidad o son más atractivas para los delincuentes

	debido a su valor de reventa.
payment_method	Filtro orientado a evaluar la seguridad de la infraestructura de cobro (tarjetas, billeteras digitales). Permite cruzar datos para ver si un método específico está siendo vulnerado de forma sistemática.

Generación de Visualizaciones mediante IA (Q&A)

Como parte de los requerimientos avanzados del proyecto, se utilizó el motor de Inteligencia Artificial de Power BI para traducir preguntas de lenguaje natural a gráficos estándar. Se seleccionaron cuatro métricas clave para componer el panel central:


- **Suma de amount_aed por merchant_category:** Gráfico que cuantifica el impacto financiero del fraude distribuido por sector comercial.
- **Conteo de transaction_id por device_type:** Gráfico diseñado para identificar el principal vector de ataque desde la perspectiva del hardware (dispositivos móviles frente a equipos de escritorio).
- **Suma de amount_aed por shipping_city:** Visualización del destino logístico del fraude, permitiendo ubicar zonas geográficas críticas para los envíos ilícitos.
- **Suma de fraud_flag_velocity por payment_method:** Métrica de comportamiento que detecta ataques de ráfaga o automatizados, indicando qué métodos de pago sufren intentos repetitivos en cortos periodos de tiempo.

Guía de Interpretación de Resultados


El diseño del panel permite un análisis multidimensional. La forma correcta de interpretar los resultados obtenidos es a través de la metodología "Top-Down" (de lo general a lo particular): Primero, el usuario debe accionar el segmentador is_fraud = 1. Inmediatamente, la tarjeta principal mostrará el monto económico total comprometido. Si posteriormente se selecciona una categoría como "Electronics", todas las gráficas generadas por el Q&A se adaptarán. El estudiante o analista puede observar si, en esa categoría específica, el fraude proviene mayoritariamente de dispositivos móviles y hacia qué ciudades se está enviando la mercancía. Esta triangulación de variables es lo que permite detectar una firma de fraude (un patrón repetitivo de comportamiento delictivo).

vinculación del dashboard:


payment_method	fecha_sola	Volumen x MetodoPago	Total Fraude	Incidencia Fraude %	Pérdida Total AED
apple_pay	12/31/2023 12:00:00 AM		4		
bank_transfer	12/31/2023 12:00:00 AM		7		
card	12/31/2023 12:00:00 AM		62	4	6.45
google_pay	12/31/2023 12:00:00 AM		9		
paypal	12/31/2023 12:00:00 AM		7		
apple_pay	1/1/2024 12:00:00 AM		21	2	9.52
bank_transfer	1/1/2024 12:00:00 AM		17		
card	1/1/2024 12:00:00 AM		184	21	11.41
Total		100000	8211	8.21	1,628,333.28



Total Fraude by payment_method



Promedio IP Risk Fraude and Promedio IP Risk Legítimo



Tipo de Transacción

1

Categoría del Comercio

- ☐ Beauty
- ☒ Digital Goods
- ☐ Electronics
- ☐ Fashion
- ☐ Groceries
- ☐ Home & Furniture
- ☐ Pharmacy
- ☐ Sports
- ☐ Toys
- ☐ Travel


Método de Pago

- ☐ apple_pay
- ☒ bank_transfer
- ☐ card
- ☐ google_pay
- ☐ paypal

Total Defraudado (AED)

8.77K

Ciudades con mayor impacto económico por fraude





Tasa_Fraude_KPI and
Objetivo_Fraude by Date

12.50~
Goal: 1 (+1,150%)

Clasificación Riesgo IP

- Alto Riesgo
- Bajo Riesgo
- Riesgo Medio

Conclusiones.

Armando Tepale Chocolatl

- A manera de conclusión, este proyecto evidencia que la efectividad en la mitigación del fraude digital no depende únicamente de la cantidad de datos recopilados, sino de la capacidad para interpretarlos con agilidad. Al centralizar métricas críticas como el impacto financiero por categoría de comercio, la velocidad de las transacciones sospechosas y la concentración geográfica en una sola interfaz interactiva, se elimina la dispersión de la información.

Erik Garcia Chavez

- El desarrollo del SSD demostró que un modelo estrella con medidas DAX dinámicas permite cuantificar el fraude y detectar vulnerabilidades operativas. Utilizando tablas, gráficos de barras y líneas, Q&A, slicers, KPI y cards, se logró un dashboard interactivo que responde a los objetivos de negocio. Aunque el KPI nativo presentó problemas técnicos, se complementa con otros visualizadores para mantener la funcionalidad requerida.

Andrea Sofia Chavez Munguia

- La coherencia entre los objetivos de la fase de inteligencia y las medidas implementadas como Clasificación Riesgo IP y Brecha Riesgo IP, fue clave para transformar datos en alertas accionables. Los slicers, gráficos de barras y líneas, Q&A y cards facilitaron el análisis multidimensional del fraude, permitiendo a la gerencia monitorear pérdidas, identificar canales vulnerables y filtrar por nivel de riesgo IP.