



Universidad autónoma de baja california

Ingeniería en computación

Ingeniería de negocios

**Meta 2.2: Aplicar las fases del marco de desarrollo
de Herbert A. Simon**

SUKEY SAYONARA NAKASIMA LOPEZ

Garcia Chaves erik

Armando Tepale Chicolatl

Andrea Sofia Chavez Munguia

Justificación:

El presente proyecto se fundamenta en el análisis de un conjunto de datos transaccionales perteneciente al sector de comercio electrónico en los Emiratos Árabes Unidos (UAE). Este archivo proporciona una radiografía detallada de las operaciones digitales, el comportamiento de los usuarios y las vulnerabilidades del sistema. el dataset cuenta con las siguientes características de calidad y volumen:

- Contiene un total de 100,000 registros de transacciones
- Contiene apartados de alto interés como el *monto*, *el tipo de cambio*, *método de cambio*, *dispositivo en donde se realizó*, *la categoría de la compra*, *direcciones ip* y *el nivel de riesgo*. etc.

Objetivo del análisis:

El objetivo central de este análisis es aplicar las fases del marco de toma de decisiones de Herbert A. Simon (Inteligencia, Diseño, Selección e Implementación) para resolver la problemática del fraude transaccional. Antes de proponer alguna solución tecnológica, la gerencia necesita comprender la gravedad del problema y establecer una línea base. Por lo tanto, se busca auditar el entorno tecnológico de la tienda para descubrir el "modus operandi" de los estafadores. Con base en esta inteligencia de datos, el propósito final es diseñar e implementar un sistema de prevención que logre frenar las pérdidas económicas sin afectar la experiencia de compra de los clientes legítimos.

Fase 1: inteligencias - definición de objetivos y métricas

Objetivo 1: cuantificar la magnitud y el impacto económico del fraude

- **Justificación:** antes de proponer alguna solución, la gerencia necesita comprender la gravedad del problema. Este objetivo busca establecer una "línea base" que permita saber exactamente cuánto dinero y qué volumen de operaciones se están perdiendo a manos de los estafadores
 - **métrica 1.1: tasa de fraude general (%)**
 - **Definición:** Es el porcentaje total de transacciones que resultaron ser fraudulentas en comparación con el volumen total de ventas.
 - **fórmula:**
$$\text{tasa de fraude} = \left(\frac{\text{número de transacciones con is-fraud}=1}{\text{total de transacciones de dataset}} \right) \times 100$$
 - **Valor de negocio:** Permite a la empresa compararse con los estándares de la industria del e-commerce. Si la tasa es anormalmente alta, justifica la inversión urgente en herramientas de seguridad de alto costo. valores >1% indican

un problema grave, el dataset muestra ~8.2% de fraude, lo cual es muy alto.

- **métrica 1.2: pérdida económica total por fraude (AED - Dirham de los EAU)**

- **Definición:** Representa la fuga de capital real; es decir, la suma monetaria de todos los artículos o servicios que fueron adquiridos ilícitamente y que resultará en "chargebacks" para la empresa.
- **fórmula:** $\Sigma(\text{ammount_aed donde is_fraud} = 1)$
- **valor de negocio:** permite dimensionar el impacto financiero real, se puede complementar con promedio de pérdida por fraude. dentro del dataset la pérdida ronda los **1.63M de AED cerca de los ~443.800 dils**

Objetivo 2: Detectar vulnerabilidades operativas en el proceso de compra.

- **Justificación:** los delincuentes suelen explotar los canales que tienen las barreras de seguridad más bajas. Este objetivo busca auditar el entorno tecnológico de la tienda (sistemas operativos, navegadores, pasarelas de pago) para descubrir el "modus operandi" y los puntos ciegos del sistema.

- **métrica 2.1: incidencia de fraude por método de pago (%)**

- **definición:** Mide la concentración de ataques exitosos agrupados por el canal financiero utilizado
- **fórmula:**
$$\text{fraude por método} = \left(\frac{\text{número de fraudes en cada método}}{\text{total de fraudes}} \right) \times 100$$
- **valor de negocio:** Si se descubre que el 80% de los fraudes ocurren usando tarjetas de crédito tradicionales, la empresa puede tomar la decisión operativa de exigir un paso extra de autenticación (como un código SMS o 3D Secure) exclusivamente para ese método, sin afectar la fluidez de compra de los usuarios que usan Apple Pay.

- **métrica 2.2: brecha de riesgo de IP (puntuación promedio)**

- **Definición:** Evalúa el nivel de amenaza técnica de las conexiones. Compara el puntaje de riesgo de las direcciones de internet (IPs) de los clientes legítimos contra las IPs de los estafadores.
- **fórmula:**
$$\text{Promedio IP riesgo (fraude)} = \text{PROMEDIO}(ip_risk_score | is_fraud = 1)$$
$$\text{Promedio IP riesgo (legítimo)} = \text{PROMEDIO}(ip_risk_score | is_fraud = 0)$$
- **valor de negocio:** Ayuda a calibrar los firewalls. Si el promedio de riesgo IP de un fraude es mayor a 70, la empresa puede diseñar una regla automatizada para bloquear o mandar a revisión manual cualquier compra futura que supere ese umbral.

Objetivo 3: analizar patrones en el comportamiento de usuario:

Justificación: Un cliente legítimo tiene un comportamiento de compra lógico y pausado, mientras que un estafador suele tener prisa por convertir los datos robados en bienes antes de ser detectado. Este objetivo busca perfilar las actitudes de los atacantes para crear "fricciones positivas" que los detengan.

- **métrica 3.1: tasa de discrepancia geográfica (%)**

- **Definición:** Cuantifica la proporción de fraudes que ocurren cuando los datos físicos del cliente no cuadran; específicamente, cuando el lugar a donde se enviará el producto no es el mismo que la dirección registrada en la tarjeta.
- **Fórmula:**
$$\%Discrepancia\ env\acute{o} - facturaci\acute{o}n\ (fraude) = \frac{Total\ fraudes\ Fraud\ es\ con\ shipping_billing_match = 0}{Total\ fraudes} \times 100$$
$$\%Discrepancia\ pa\acute{s}\ tarjeta\ (fraude) = \frac{Total\ fraudes\ Fraud\ es\ con\ card_country_match = 0}{Total\ fraudes} \times 100$$
- **Valor de negocio:** Es un indicador clásico de robo de identidad (el estafador usa la tarjeta de una víctima en otro país, pero pide que el paquete llegue a su domicilio local). Esto fundamenta la decisión de pausar envíos internacionales que presenten esta alerta.

- **Métrica 3.2: velocidad de transacción anómala (volumen promedio)**

- **Definición:** Identifica ataques de "fuerza bruta" o "cash-out" rápido, midiendo la frecuencia con la que una sola cuenta intenta realizar compras en un periodo muy corto.
- **fórmula:**
$$Promedio\ transacciones\ u\acute{l}tima\ hora\ (alto\ riesgo) = PROMEDIO(transacciones_last_1h|user_is_high_risk = 1)$$
$$Promedio\ transacciones\ u\acute{l}tima\ hora\ (normal) = PROMEDIO(transacciones_last_1h|user_is_high_risk = 0)$$
- **valor de negocio:** Los estafadores suelen hacer "pruebas" rápidas de montos pequeños para ver si la tarjeta robada funciona, seguidas de compras grandes. Medir esto permite a la empresa implementar bloqueos temporales a cuentas que superen, por ejemplo, 3 intentos de compra en menos de 1 hora.

Fase de diseño

En esta fase se proponen tres alternativas de solución. No se trata solo de listar herramientas, sino de pensar qué tipo de estrategia podría funcionar mejor según el patrón de fraude que muestra el dataset.

Alternativa 1: sistema basado principalmente en reglas de negocio

Esta primera alternativa consistiría en implementar reglas simples para detectar transacciones sospechosas. Por ejemplo, una compra podría marcarse si el correo electrónico pertenece a un dominio desechable, si la IP tiene un riesgo alto, si el país de la tarjeta no coincide con el país de la transacción o si el usuario ya tiene antecedentes de chargebacks.

Esta opción es útil porque puede ponerse en marcha de manera rápida y con bajo costo. Además, es fácil de entender para el equipo operativo, ya que cada alerta tendría una razón clara detrás. Por ejemplo, si una compra llega desde una IP riesgosa y además el correo es temporal, el sistema puede bloquearla o mandarla a revisión manual sin necesidad de cálculos complejos.

Sin embargo, esta alternativa también tiene limitaciones. El principal problema es que funciona con reglas fijas, y el fraude cambia constantemente. Eso significa que si los atacantes ajustan su comportamiento, las reglas pueden quedarse cortas. Además, un sistema totalmente basado en reglas puede generar falsos positivos, es decir, bloquear clientes reales solo porque cumplen una condición de riesgo.

Por qué esta alternativa sí podría servir

Porque para una empresa que apenas empieza a organizar su control antifraude, puede funcionar como una primera barrera. No resuelve todo, pero sí ayuda a filtrar casos muy obvios y a proteger la operación desde el inicio.

Alternativa 2: sistema híbrido con reglas de negocio y modelo predictivo

Esta segunda alternativa combina lo mejor de los dos mundos. Por un lado, mantiene reglas básicas para detectar casos evidentes; por otro, incorpora un modelo predictivo que analiza varias variables al mismo tiempo y asigna un nivel de riesgo a cada transacción.

Las variables que más sentido tienen para este caso son las que el propio dataset demuestra como relevantes:

- método de pago,
- puntaje de riesgo de IP,
- país de la tarjeta,
- coincidencia entre envío y facturación,
- correo electrónico,
- historial de chargebacks,
- antigüedad de la cuenta,

- y si la compra ocurre en un horario inusual.

La razón por la que esta alternativa es más sólida es que el fraude normalmente no se identifica por una sola señal, sino por la combinación de varias. Por ejemplo, una compra hecha con tarjeta, desde una IP riesgosa, con un correo desechable y con país de tarjeta diferente al país de operación, tiene un perfil claramente sospechoso. El problema es que si solo se mira una variable por separado, esa compra podría parecer normal. Por eso el enfoque híbrido ayuda mucho más.

Por qué esta alternativa es mejor que la primera

Porque no depende únicamente de reglas estáticas. El modelo predictivo puede aprender patrones históricos y detectar combinaciones de variables que un sistema simple no vería. Además, permite ajustar la sensibilidad del sistema para evitar tantos falsos positivos.

Por qué esta alternativa sigue siendo viable

Porque no necesita una infraestructura extremadamente cara. Se puede desarrollar con herramientas accesibles como Python, pandas, scikit-learn y PostgreSQL, lo que la hace realista para una empresa que quiere mejorar su control sin gastar de más desde el principio.

Alternativa 3: plataforma integral automatizada de detección de fraude

La tercera alternativa sería una solución más avanzada, casi a nivel empresarial completo. Aquí no solo habría reglas y modelos predictivos, sino también automatización, monitoreo en tiempo real e integración con fuentes externas de datos.

En esta opción, cada transacción recibirá un puntaje de riesgo y el sistema podría decidir de manera automática si:

- se aprueba,
- se bloquea,
- o se envía a revisión manual.

Además, esta plataforma podría conectarse con bases externas de IP, BIN, reputación de correo y otros servicios antifraude más especializados.

Ventajas de esta alternativa

Tiene la mayor capacidad de detección y la mejor escalabilidad. También permite reaccionar rápido ante nuevos patrones de fraude, algo que es muy importante cuando el volumen de transacciones crece.

Desventajas

Su costo y complejidad son mayores. No solo requiere más tecnología, sino también más personal capacitado, mayor mantenimiento y un proceso de integración más largo. Por eso, aunque es la opción más completa, no siempre es la más conveniente como primer paso.

Fase de selección

Después de comparar las tres alternativas, la opción ganadora es la Alternativa 2: sistema híbrido con reglas de negocio y modelo predictivo.

¿Por qué gana esta opción?

Porque ofrece un equilibrio muy bueno entre costo, precisión y facilidad de implementación. No es tan básica como un sistema solo de reglas, pero tampoco tan costosa y compleja como una plataforma totalmente automatizada. Además, el dataset muestra que sí existen patrones claros de fraude que pueden aprovecharse con un modelo, pero también hay señales operativas que conviene conservar como reglas.

¿Qué aporta de forma práctica?

Permite usar primero filtros simples para casos evidentes y después aplicar el modelo predictivo para analizar transacciones más complejas. Esto mejora la capacidad de detección sin afectar demasiado a los clientes legítimos.

¿Por qué es la más razonable para una entrega universitaria y para una empresa real?

Porque muestra una solución madura, pero no exageradamente costosa. Es decir, se nota que hay análisis detrás, pero también sentido práctico. Eso la hace mucho más defendible frente a una gerencia o en una exposición académica.

Fase de implementación

La implementación debe hacerse por etapas, porque si se intenta cambiar todo de golpe, el sistema puede volverse difícil de controlar. Lo correcto es avanzar poco a poco y medir resultados en cada paso.

Etapla 1: diagnóstico inicial

En esta primera etapa se analiza el problema con detalle para tener una línea base clara. Aquí se revisa la calidad de los datos, se identifican las variables más útiles y se calculan las métricas principales.

En este dataset, por ejemplo, ya se sabe que hay:

- **100,000 registros**
- **36 variables**
- **0 valores faltantes**
- **8.21% de fraude**
- **1,628,333.28 AED de pérdida total**

Eso permite partir de una base sólida. Esta etapa es importante porque ayuda a entender dónde está el problema y qué señales tienen más peso. Sin este diagnóstico, cualquier solución quedaría basada más en suposiciones que en evidencia.

Etapla 2: diseño de la solución

Después del diagnóstico, se define cómo va a funcionar la solución. Aquí se construyen las reglas de negocio y se eligen las variables que alimentarán el modelo predictivo.

Por ejemplo, el análisis muestra que:

- los usuarios con historial de chargebacks tienen una tasa de fraude de 27.24%,
- los usuarios de alto riesgo presentan 22.07% de fraude,
- las cuentas nuevas tienen 12.69%,
- y las compras con país de tarjeta distinto al país de operación alcanzan 9.37%.

Estas cifras muestran que no todas las variables tienen el mismo peso. Algunas son claramente más peligrosas que otras, así que el diseño debe darle prioridad a esas señales. En esta etapa también se define qué hacer con cada caso: aprobar, bloquear o mandar a revisión.

Etapla 3: desarrollo y prueba piloto

Una vez diseñado el sistema, se debe probar antes de implementarlo por completo. Esta fase sirve para verificar si las reglas y el modelo realmente detectan fraude sin bloquear demasiadas compras legítimas.

Aquí sería útil revisar casos como:

- pagos con tarjeta, que concentran 70.0% de las transacciones y 69.67% de los fraudes,
- dominios de correo desechables, como tempmail.com (22.91%), 10minutemail.com (20.57%), disposable.com (20.32%) y mailinator.com (19.43%),
- e IPs de mayor riesgo, donde el promedio en fraudes es 46.25, frente a 39.24 en transacciones legítimas.

Esta etapa sirve para ajustar el sistema antes de usarlo en toda la operación. Si detecta demasiados casos incorrectos, se afinan las reglas o se re entrena el modelo.

Etapas 4: implementación gradual

Cuando el piloto ya funciona bien, la solución se debe aplicar poco a poco. No conviene activarla de golpe en todas las transacciones porque eso podría generar bloqueos innecesarios o afectar la experiencia del cliente.

Lo más lógico sería empezar por los casos de mayor riesgo, como:

- cuentas nuevas,
- correos desechables,
- pagos con tarjeta,
- operaciones con discrepancia geográfica,
- o usuarios con chargebacks previos.

De esta forma se reduce el riesgo de errores operativos y se permite que el equipo aprenda a trabajar con el sistema sin presionarlo demasiado desde el inicio.

Etapas 5: monitoreo y mejora continúa

La implementación no termina cuando el sistema entra en funcionamiento. De hecho, esta es una de las etapas más importantes, porque el fraude cambia constantemente.

En esta fase se deben revisar indicadores como:

- Tasa mensual de fraude
- Número de alertas generadas
- Porcentaje de falsos positivos
- Monto recuperado o evitado
- Reducción de pérdidas económicas.

También hay que revisar si surgen nuevos patrones, porque los atacantes cambian de métodos cuando detectan que la empresa fortalece sus controles. Por eso, el sistema debe actualizarse periódicamente, ajustar reglas y, si es necesario, volver a entrenar el modelo con datos recientes.

Conclusiones:

Armando Tepale Chocolatl.

A partir de este trabajo, pude darme cuenta de que el fraude en comercio electrónico no es algo aislado, sino un problema que puede medirse claramente con datos y que tiene un impacto económico importante. Analizar el dataset ayudó a entender que existen patrones muy marcados, como el uso de tarjetas, correos desechables o discrepancias de país, que facilitan identificar comportamientos sospechosos.

También considero que la propuesta del sistema híbrido es la más adecuada, porque no se queda solo en reglas simples, pero tampoco requiere una infraestructura tan compleja. Es una solución más realista y aplicable, especialmente para una empresa que quiere mejorar sin hacer una inversión demasiado grande desde el inicio.

En general, este trabajo me permitió entender mejor cómo se pueden usar los datos para tomar decisiones más informadas y cómo la tecnología puede ayudar a reducir riesgos dentro de una empresa.

Erik Garcia chavez:

El desarrollo de este proyecto me permitió comprobar que el fraude en el comercio electrónico trasciende de ser un simple fallo técnico a convertirse en un problema con un impacto económico severo que puede y debe medirse con precisión. Al analizar los datos quedó en evidencia el modus operandi de los distintos delincuentes como puede ser el uso de correo desechables, discrepancias geográficas y métodos de pago específicos. El marco de toma de decisiones de Herbert A. Simon fue clave para estructurar una solución. Se demostró como el correcto procesamiento de la información permite transformar vulnerabilidades en estrategias de defensa sólidas, protegiendo tanto los ingresos de la compañía como la experiencia de los clientes.

Andrea Sofia Chavez Munguia

A lo largo de este proyecto se vio la importancia de aplicar un enfoque estructurado como el modelo de Herbert A. Simon para resolver problemas reales dentro del ámbito empresarial. El análisis del dataset permitió identificar que el fraude en el comercio electrónico no solo es frecuente, sino que presenta patrones claros que pueden ser aprovechados para su detección.

Finalmente este trabajo nos permitió fortalecer la comprensión sobre el papel de la ingeniería en computación en la toma de decisiones pudiendo destacar cómo el uso adecuado de la tecnología y los datos puede contribuir significativamente a la solución de problemas complejos y a la mejora continua de los procesos organizacionales.

Referencias:

- BBVA. (2023). Qué es el fraude electrónico y cómo prevenirlo. BBVA. <https://www.bbva.com/es/que-es-el-fraude-electronico-y-como-prevenirlo/>
- Kaspersky. (2022). ¿Qué es el fraude en línea y cómo protegerse?. Kaspersky. <https://latam.kaspersky.com/resource-center/threats/online-fraud>
- Instituto Nacional de Ciberseguridad (INCIBE). (2023). Fraude online: cómo identificarlo y prevenirlo. INCIBE. <https://www.incibe.es>
- OBS Business School. (2021). Big Data y toma de decisiones en las empresas. OBS Business School. <https://www.obsbusiness.school>
- IBM. (2023). Qué es el machine learning. IBM. <https://www.ibm.com/mx-es/topics/machine-learning>
- Microsoft. (2022). Análisis de datos: qué es y por qué es importante. Microsoft. <https://learn.microsoft.com/es-es>
- Economipedia. (2023). Comercio electrónico (e-commerce). Economipedia. <https://economipedia.com/definiciones/comercio-electronico.html>
- CyberSource. (2022). Fraude en comercio electrónico: tendencias y prevención. CyberSource. <https://www.cybersource.com>
- Statista. (2023). Fraude en comercio electrónico a nivel mundial. Statista. <https://es.statista.com>
- Google Cloud. (2023). Qué es el análisis de datos. Google Cloud. <https://cloud.google.com/learn/what-is-data-analytics?hl=es>